

ML 2019 Hw3 Report

學號：b05705042 系級：資管四 姓名：皇甫立翔

1. 請說明這次使用的 model 架構，包含各層維度及連接方式。

這次用的架構是 CNN + Linear (dense) 堆疊起來的。

連續疊了4層 CNN 之後，接著攤平後再疊上三層 Fully connected linear layer，其中最後一層是 output layer。（每一層 CNN Max Pooling 都是 2）。

第一層 CNN：kernel size = 5，output channel = 32，padding = 2

第二層 CNN：kernel size = 3，output channel = 64，padding = 1

第三層 CNN：kernel size = 3，output channel = 128，padding = 1

第四層 CNN：kernel size = 3，output channel = 128，padding = 1

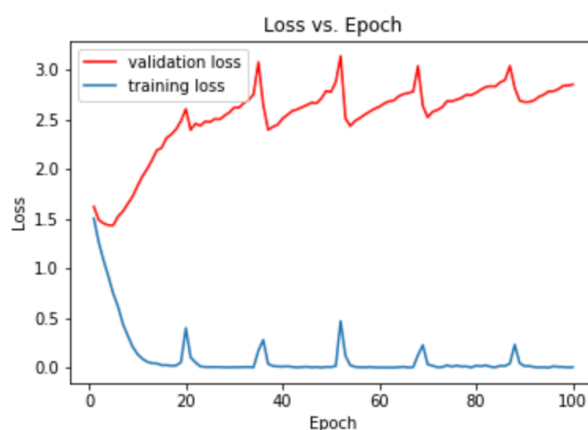
第一層 Linear：input channel = $3 \times 3 \times 128$ ，output channel = 256

第二層 Linear：input channel = 256，output channel = 128

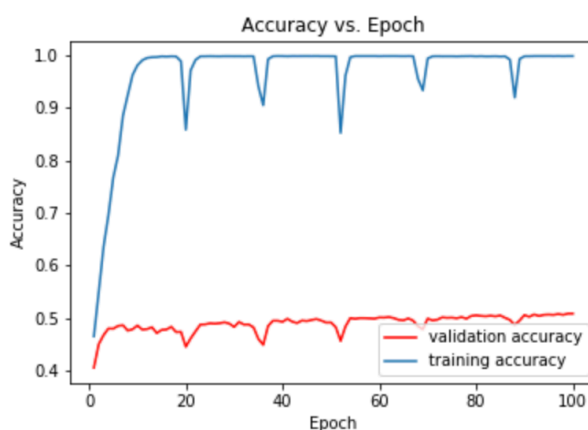
第三層 Linear (Output)：input channel = 128，output channel = 7

2. 請附上 model 的 training / validation history (loss and accuracy)。


Loss



Accuracy




3. 畫出 Confusion Matrix 分析哪些類別的圖片容易使 model 搞混，並簡單說明。



0 = Angry 1 = Disgust 2 = Fear 3 = Happy 4 = Sad 5 = Surprise 6 = Neutral


經由 Confusion Matrix 可以看得出來，(1) Fear vs. Sad (2) Fear vs. Neutral 的圖片，相較其他類別來說，比較容易使 model 搞混，他們在 matrix 中的數字比較大，意即有較高機率使 model 搞混。

4. 畫出 CNN model 的 saliency map，並簡單討論其現象。



顏色較顯眼的部分即是 feature 影響較大的地方。

5. 畫出最後一層的 filters 最容易被哪些 feature activate。




6. Refer to math problem.

1. 原本的 shape = (B, w, H, input-channels)

$$\text{寬} = \frac{(w + 2 \cdot p_1) - k_1}{s_1} + 1$$

$$\text{長} = \frac{(H + 2 \cdot p_2) - k_2}{s_2} + 1$$



605705042
李甫立翔

Ans: 經過 convolution layer 後, shape 變成 $(B, \frac{(w + 2 \cdot p_1) - k_1}{s_1} + 1, \frac{(H + 2 \cdot p_2) - k_2}{s_2} + 1, \text{output-channels})$

2.

$$(1) \frac{\partial L}{\partial \hat{x}_i} = \frac{\partial L}{\partial y_i} \gamma \quad (2) \frac{\partial L}{\partial \sigma^2 \beta} = \sum_{i=1}^m \frac{\partial L}{\partial \hat{x}_i} \cdot (x_i - \mu \beta) \cdot \frac{1}{2} (\sigma^2 \beta + \epsilon)^{-\frac{3}{2}}$$

$$(3) \frac{\partial L}{\partial \mu \beta} = \left(\sum_{i=1}^m \frac{\partial L}{\partial \hat{x}_i} \cdot \frac{1}{\sqrt{\sigma^2 \beta + \epsilon}} \right) + \frac{\partial L}{\partial \sigma^2 \beta} \cdot \frac{\sum_{i=1}^m -2(x_i - \mu \beta)}{m}$$

$$(4) \frac{\partial L}{\partial x_i} = \frac{\partial L}{\partial \hat{x}_i} \cdot \frac{1}{\sqrt{\sigma^2 \beta + \epsilon}} + \frac{\partial L}{\partial \sigma^2 \beta} \cdot \frac{2(x_i - \mu \beta)}{m} + \frac{\partial L}{\partial \mu \beta} \cdot \frac{1}{m}$$

$$(5) \frac{\partial L}{\partial \gamma} = \sum_{i=1}^m \frac{\partial L}{\partial y_i} \cdot \hat{x}_i \quad (6) \frac{\partial L}{\partial \beta} = \sum_{i=1}^m \frac{\partial L}{\partial y_i}$$

3.

此處 L 當中 $y_t = 1$ 的項, 在這邊直接對 L 微分.

$$L = -\sum_i y_i \log(\hat{y}_i)$$

$$\frac{\partial L}{\partial z_t} = \frac{\partial (-\sum_i y_i \log(\hat{y}_i))}{\partial z_t} = -\sum_i y_i \frac{1}{\hat{y}_i} \frac{\partial \hat{y}_i}{\partial z_t}$$

$$\text{根據 softmax 微分公式可轉化為} = -y_t (1 - \hat{y}_t) - \sum_{i \neq t} y_i \frac{1}{\hat{y}_i} (-\hat{y}_i \hat{y}_t)$$

$$= -y_t (1 - \hat{y}_t) + \sum_{i \neq t} y_i \hat{y}_t$$

$$= -y_t + y_t \hat{y}_t + \sum_{i \neq t} y_i \hat{y}_t$$

$$= \hat{y}_t \cdot \sum_i y_i - y_t, \text{ 其中 } \sum_i y_i = 1$$

$$\Rightarrow \frac{\partial L}{\partial z_t} = \hat{y}_t - y_t \text{ 得證}$$